

# Árvores de decisão

- Aprendizado supervisionado
- Geração de regras a partir de dados
  - Nominais ou numéricos
- Usa a teoria do “ganho de informação”
- A raiz da árvore contém o atributo “mais informativo” ou “mais discriminativo”
  - E vai descendente por ordem deste ganho de informação



# Ideia central

- Classificação particionando o espaço de exemplos
- Aprendizado das classes discretas (não contínuas)
  - Valor de  $Y$  deve ser discreto ou nominal, não deve ser numérico-contínuo
- Um exemplo (clássico da área)
  - Criado pelo idealizador do algoritmo, Ross Quinlan (década de 80)
  - Observar as variáveis climáticas que podem favorecer um jogo de tênis em quadra aberta
  - 14 observações



# Jogar tênis


Dia	Aparência	Temperatura	Umidade	Vento	Jogar tênis?
D1	sol	quente	alta	fraca	<b>não</b>
D2	sol	quente	alta	forte	<b>não</b>
D3	nublado	quente	alta	fraca	<b>sim</b>
D4	chuva	amena	alta	fraca	<b>sim</b>
D5	chuva	fria	normal	fraca	<b>sim</b>
D6	chuva	fria	normal	forte	<b>não</b>
D7	nublado	fria	normal	forte	<b>sim</b>
D8	sol	amena	alta	fraca	<b>não</b>
D9	sol	fria	normal	fraca	<b>sim</b>
D10	chuva	amena	normal	fraca	<b>sim</b>
D11	sol	amena	normal	forte	<b>sim</b>
D12	nublado	amena	alta	forte	<b>sim</b>
D13	nublado	quente	normal	fraca	<b>sim</b>
D14	chuva	amena	alta	forte	<b>não</b>

Exercício:

Contemple esta tabela por uns 5 a 10 min e tente obter padrões de que, em que condições climáticas pode haver ou não o jogo.

Ex. basta estar nublado para ter jogo.  
(é um padrão que só depende de um atributo, a aparência)



# Uma árvore de decisão mostra as regras que descrevem este padrão



# Regras de decisão, a partir da árvore

- Se (Aparência == ‘sol’) e (Umidade == ‘alta’) então Jogar = ‘NÃO’
- Se (Aparência == ‘sol’) e (Umidade == ‘normal’) então Jogar = ‘SIM’
- Se (Aparência == ‘nublado’) então Jogar = ‘SIM’
- Se (Aparência == ‘chuva’) e (Vento == ‘forte’) então Jogar = ‘NÃO’
- Se (Aparência == ‘chuva’) e (Vento == ‘fraco’) então Jogar = ‘SIM’

# Reescrevendo as regras: lógica aprimorada




# Reescrevendo as regras: lógica aprimorada

- Se (Aparência == 'sol') e (Umidade == 'normal')  
ou (Aparência == 'nublado')  
ou (Aparência == 'chuva') e (Vento == 'fraco')  
então Jogar = 'SIM'
- Se (Aparência == 'sol') e (Umidade == 'alta')  
ou (Aparência == 'chuva') e (Vento == 'forte')  
então Jogar = 'NÃO'



# Outro exemplo: Dados categorizados em mais classes: 26 frutas




FRUTA	COR	EIXO PRINC	DIÂM TRAN	TIPO
A	Verde	12,3 cm	2,8 cm	BANANA
B	Verde	2,3 cm	2,2 cm	UVA
C	Amarela	12,7 cm	2,3 cm	BANANA
D	Roxa	2,3 cm	1,9 cm	UVA
E	Verde	10,1 cm	7,4 cm	ABACATE
...	etc.	etc.	etc.	etc.

# Regras de decisão, a partir da árvore (frutas)

- Se ( $\text{Cor} == \text{'amarela'}$ ) e ( $\text{Diam.transv.} < 3,0$ ) então Fruta = 'BANANA'
- Se ( $\text{Cor} == \text{'amarela'}$ ) e ( $\text{Diam.transv.} \geq 3,0$ ) então Fruta = 'MAMÃO'
- Se ( $\text{Cor} == \text{'roxa'}$ ) então Fruta = 'UVA'
- Se ( $\text{Cor} == \text{'verde'}$ ) e ( $\text{Eixo Princ} < 5,0$ ) então Fruta = 'UVA'
- Se ( $\text{Cor} == \text{'verde'}$ ) e ( $\text{Eixo Princ} \geq 5,0$ ) e ( $\text{Eixo Princ} < 15,0$ ) então Fruta = 'ABACATE'
- Se ( $\text{Cor} == \text{'verde'}$ ) e ( $\text{Eixo Princ} \geq 15,0$ ) então Fruta = 'BANANA'

# Usando a técnica anterior, de agrupar as regras pela classe Y:

- Se (Cor == 'amarela') e (Diam.transv. < 3,0)  
ou (Cor == 'verde') e (Eixo Princ ≥ 15,0)  
então Fruta = 'BANANA'
- Se (Cor == 'amarela') e (Diam.transv. ≥ 3,0) então Fruta = 'MAMÃO'
- Se (Cor == 'roxa') ou (Cor == 'verde')  
e (Eixo Princ < 5,0)  
então Fruta = 'UVA'
- Se (Cor == 'verde') e (Eixo Princ ≥ 5,0) e (Eixo Princ < 15,0)  
então Fruta = 'ABACATE'



Não esqueça das  
precedências lógicas:  
**e** é processado antes  
de **ou** EM QUALQUER  
LINGUAGEM


# Resumo

**DADOS**

FRUTA	COR	EIXO PRINC	DIÂM TRAN	TIPO
A	Verde	12,3 cm	2,8 cm	BANANA
B	Verde	2,3 cm	2,2 cm	UVA
C	Amarela	12,7 cm	2,3 cm	BANANA
D	Roxa	2,3 cm	1,9 cm	UVA
E	Verde	10,1 cm	7,4 cm	ABACATE
...	etc.	etc.	etc.	etc.

AL  
GO  
RIT  
MO

**ÁRVORE**





**REGRAS LÓGICAS**

Dia	Aparência	Temperatura	Umidade	Vento	Jogar tênis?
D1	sol	quente	alta	fraca	não
D2	sol	quente	alta	forte	não
D3	nublado	quente	alta	fraca	sim
D4	chuva	amena	alta	fraca	sim
D5	chuva	fria	normal	fraca	sim
D6	chuva	fria	normal	forte	não

- SE Tipo de Acidente = Atropelamento de Animal E Modelo da Pista = Reta E Tipo de Veículo = Automóvel E Período do Dia = Noite ENTÃO Causa do Acidente = Animais na Pista. (#Cob = 1036; #Incorr = 17)
- SE Tipo de Acidente = Incêndio E Estado Físico da Pessoa = Iteso E Modelo da Pista = Reta ENTÃO Causa do Acidente = Defeito Mecânico no Veículo. (#Cob = 628; #Incorr = 7)
- SE Tipo de Acidente = Incêndio E Dia da Semana = Quarta-feira E Período do Dia = Manhã ENTÃO Causa do Acidente = Motorista Dormindo. (#Cob = 16)
- SE Tipo de Acidente = Atropelamento de Pessoa E Modelo da Pista = Reta E Período do Dia = Tarde e Tipo de Veículo = Automóvel ENTÃO Causa do Acidente = Falta de Atenção. (#Cob = 343; #Incorr = 85)

## Outros casos:



# Teoria: como é calculado o ganho de informação?

- Qual atributo é o melhor?
  - Selecione o atributo que é mais útil para classificar exemplos.
- Medida quantitativa
  - **Ganho de informação**
- Para o atributo A, em relação a uma coleção de dados D

$$Gain(D, A) \equiv Entropy(D) - \sum_{v \in Values(A)} \frac{|D_v|}{|D|} Entropy(D_v)$$


- Redução esperada de entropia

# Entropia (informação)

- Impureza de uma coleção arbitrária de exemplos

$$Entropy(D) \equiv - \sum_{i=1}^c p_i \log p_i$$

- Número mínimo de bits de informação necessários para codificar a classificação de um membro arbitrário de D



### ID3(*Examples*, *Target\_attribute*, *Attributes*)

*Examples* are the training examples. *Target\_attribute* is the attribute whose value is to be predicted by the tree. *Attributes* is a list of other attributes that may be tested by the learned decision tree. Returns a decision tree that correctly classifies the given *Examples*.

- Create a *Root* node for the tree
- If all *Examples* are positive, Return the single-node tree *Root*, with label = +
- If all *Examples* are negative, Return the single-node tree *Root*, with label = -
- If *Attributes* is empty, Return the single-node tree *Root*, with label = most common value of *Target\_attribute* in *Examples*
- Otherwise Begin
  - $A \leftarrow$  the attribute from *Attributes* that best\* classifies *Examples*
  - The decision attribute for *Root*  $\leftarrow A$
  - For each possible value,  $v_i$ , of *A*,
    - Add a new tree branch below *Root*, corresponding to the test  $A = v_i$
    - Let  $Examples_{v_i}$  be the subset of *Examples* that have value  $v_i$  for *A*
    - If  $Examples_{v_i}$  is empty
      - Then below this new branch add a leaf node with label = most common value of *Target\_attribute* in *Examples*
      - Else below this new branch add the subtree  
$$ID3(Examples_{v_i}, Target\_attribute, Attributes - \{A\}))$$
- End
- Return *Root*

\* The best attribute is the one with highest *information gain*, as defined in Equation (3.4).


algoritmo

# Exemplo: jogar tênis (1)

14 dados, sendo 9 positivos (jogar) e 5 negativos (não jogar)

Cálculo da entropia do conjunto

$$\begin{aligned}Entropy(D) &= Entropy([9+, 5-]) \\&= -\frac{9}{14} \log\left(\frac{9}{14}\right) - \frac{5}{14} \log\left(\frac{5}{14}\right) \\&= 0.940\end{aligned}$$




# Exemplo: jogar tênis (2)

Atributo Vento


D = [9+,5-]

D(fraçao) = [6+,2-]

D(forte) = [3+,3-]




$$\begin{aligned} Gain(D, Wind) &= Entropy(D) - \sum_{v \in \{weak, strong\}} \frac{|D_v|}{|D|} Entropy(D_v) \\ &= Entropy(D) - \frac{8}{14} Entropy(D_{weak}) - \frac{6}{14} Entropy(D_{strong}) \\ &= 0.940 - \frac{8}{14} 0.811 - \frac{6}{14} 1.00 \\ &= 0.048 \end{aligned}$$



# Exemplo: jogar tênis (3)

Atributo Umidade  
 $D(\text{alta}) = [3+, 4-]$   
 $D(\text{normal}) = [6+, 1-]$



$$\begin{aligned} Gain(D, Wind) &= Entropy(D) - \sum_{v \in \{high, normal\}} \frac{|D_v|}{|D|} Entropy(D_v) \\ &= Entropy(D) - \frac{7}{14} Entropy(D_{high}) - \frac{7}{14} Entropy(D_{normal}) \\ &= 0.940 - \frac{7}{14} 0.985 - \frac{7}{14} 0.592 \\ &= 0.151 \end{aligned}$$

# Exemplo: jogar tênis (4)


Melhor atributo?

$$\text{Ganho}(D, \text{Outlook}) = 0,246$$

$$\text{Ganho}(D, \text{Umidade}) = 0,151$$

$$\text{Ganho}(D, \text{Vento}) = 0,048$$

$$\text{Ganho}(D, \text{Temperatura}) = 0,029$$



# Exemplo: jogar tênis (5)

Continuando próximo nível da árvore


$$\begin{aligned}Entropy(D_{sunny}) &= Entropy([2+, 3-]) \\&= -\frac{2}{5} \log\left(\frac{2}{5}\right) - \frac{3}{5} \log\left(\frac{3}{5}\right) \\&= 0.971\end{aligned}$$

<i>Day</i>	<i>Outlook</i>	<i>Temperature</i>	<i>Humidity</i>	<i>Wind</i>	<i>PlayTennis</i>
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes

## Example : Play Tennis (6)

- Attribute *Wind*

- $D_{weak} = [1+, 2-]$
- $D_{strong} = [1+, 1-]$




$$\begin{aligned}
 Gain(D, Wind) &= Entropy(D_{sunny}) - \sum_{v \in \{weak, strong\}} \frac{|D_v|}{|D|} Entropy(D_v) \\
 &= Entropy(D_{sunny}) - \frac{3}{5} Entropy(D_{weak}) - \frac{2}{5} Entropy(D_{strong}) \\
 &= 0.971 - \frac{3}{5} 0.918 - \frac{2}{5} 1.00 \\
 &= 0.020
 \end{aligned}$$

14

## Example : Play Tennis (7)

- Attribute *Humidity*

- $D_{high} = [0+, 3-]$
- $D_{normal} = [2+, 0-]$




$$\begin{aligned}
 Gain(D, Humidity) &= Entropy(D_{sunny}) - \sum_{v \in \{high, normal\}} \frac{|D_v|}{|D|} Entropy(D_v) \\
 &= Entropy(D_{sunny}) - \frac{3}{5} Entropy(D_{high}) - \frac{2}{5} Entropy(D_{normal}) \\
 &= 0.971 - \frac{3}{5} 0.00 - \frac{2}{5} 0.00 \\
 &= 0.971
 \end{aligned}$$

15

## Example : Play Tennis (8)

- Best Attribute?
  - $\text{Gain}(D, \text{Humidity}) = 0.971$
  - $\text{Gain}(D, \text{Wind}) = 0.020$
  - $\text{Gain}(D, \text{Temperature}) = 0.571$



16

SNU Center for Bioinformation Technology (CBIT)

## Example : Play Tennis (9)

- Entropy  $D_{rain}$

$$\begin{aligned} \text{Entropy}(D_{sunny}) &= \text{Entropy}([3+, 2-]) \\ &= -\frac{3}{5} \log\left(\frac{3}{5}\right) - \frac{2}{5} \log\left(\frac{2}{5}\right) \\ &= 0.971 \end{aligned}$$

Day	Outlook	Temperature	Humidity	Wind	PlayTennis
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D10	Rain	Mild	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No


17

SNU Center for Bioinformation Technology (CBIT)

## Example : Play Tennis (10)

- Attribute *Wind*

- $D_{weak} = [3+,0-]$
- $D_{strong} = [0+,2-]$




$$\begin{aligned}
 Gain(D, Wind) &= Entropy(D_{rain}) - \sum_{v \in \{weak, strong\}} \frac{|D_v|}{|D|} Entropy(D_v) \\
 &= Entropy(D_{rain}) - \frac{3}{5} Entropy(D_{weak}) - \frac{2}{5} Entropy(D_{strong}) \\
 &= 0.971 - \frac{3}{5} 0.00 - \frac{2}{5} 1.00 \\
 &= 0.971
 \end{aligned}$$

18

## Example : Play Tennis (11)

- Attribute *Humidity*

- $D_{high} = [1+,1-]$
- $D_{normal} = [2+,1-]$




$$\begin{aligned}
 Gain(D, Wind) &= Entropy(D_{rain}) - \sum_{v \in \{high, normal\}} \frac{|D_v|}{|D|} Entropy(D_v) \\
 &= Entropy(D_{rain}) - \frac{3}{5} Entropy(D_{high}) - \frac{2}{5} Entropy(D_{normal}) \\
 &= 0.971 - \frac{3}{5} 1.00 - \frac{2}{5} 0.918 \\
 &= 0.020
 \end{aligned}$$

19

# Example : Play Tennis (12)

- Best Attribute?
  - ◆  $Gain(D, \text{Humidity}) = 0.020$
  - ◆  $Gain(D, \text{Wind}) = 0.971$
  - ◆  $Gain(D, \text{Temperature}) = 0.020$




Evitando o superajuste  
Considere o seguinte:  
(Outlook = Ensolarado e  
Umidade = Normal e  
JogarTênis = Não)

Previsão errada da árvore de  
decisão  
(Outlook = Ensolarado e  
Umidade = Normal) => Sim

E se podarmos o nó  
"Umidade"?  
Quando (outlook = Sunny),  
PlayTennis => Não

Pode ser previsto  
corretamente.




Os dados nominais (categóricos) foram convertidos pelo OneHot Encoder  
Esses valores é que aparecem nesta árvore


Outlook	Temperature	Humidity	Wind	PlayTennis
Sunny	Hot	High	Weak	No
Sunny	Hot	High	Strong	No
Overcast	Hot	High	Weak	Yes
Rain	Mild	High	Weak	Yes
Rain	Cool	Normal	Weak	Yes

Outlook	Temperature	Humidity	Wind	PlayTennis
2	1	0	1	0
2	1	0	0	0
0	1	0	1	1
1	2	0	1	1
1	0	1	1	1

sepal length	sepal width	petal length	petal width	iris class
5.1	3.5	1.4	0.2	Iris-setosa
4.9	3.0	1.4	0.2	Iris-setosa
4.7	3.2	1.3	0.2	Iris-setosa
4.6	3.1	1.5	0.2	Iris-setosa
5.0	3.6	1.4	0.2	Iris-setosa
...	...	...	...	...
6.7	3.0	5.2	2.3	Iris-virginica
6.3	2.5	5.0	1.9	Iris-virginica
6.5	3.0	5.2	2.0	Iris-virginica
6.2	3.4	5.4	2.3	Iris-virginica
5.9	3.0	5.1	1.8	Iris-virginica




Flores “Iris”  
<https://archive.ics.uci.edu/dataset/53/iris>



ASSESSMENT OF  
CHEMICAL ELEMENTS  
IN COSMETICS'  
EYESHADOWS BY X-RAY  
FLUORESCENCE AND  
INTERNATIONAL  
NOMENCLATURE OF  
COSMETIC  
INGREDIENTS  
CHARACTERIZATION

2018


Santos, B.; Oliveira Jr., J.;  
**Bonventi** Jr., W.; Hanai-  
Yoshida, W.



# Random Forest (árvores aleatórias)


## Single Decision Tree

Ensemble of trees for more accurate and robust prediction




## Random Forest

Prediction from a single decision path



# Random Forest Algorithm in Machine Learning



# Random Forest



## High Accuracy

Provides reliable and precise predictions



## Handles Missing Values

The algorithm's robustness to incomplete data



## Random Forest Effectiveness

## Works with Large Datasets

Efficient processing of high-dimensional data



## Reduces Overfitting


Ensures generalization to unseen data



# Titanic dataset

Did the passenger survive?

PassengerId	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
893	3	Wilkes, Mrs. James (Ellen Needs)	female	47	1	0	363272	7		S



Tree #1 votes Survived = 1

Tree #2 votes Survived = 1

Tree #3 votes Survived = 0

Random forest predicts Survived = 1

# Evasão universitária

## revista Abakós PUC-MG – em revisão

Figura 9 – Principais atributos segundo algoritmo Random Forest.




Figura 10 – Atributos menos relevantes

